```
import pandas as pd
import os
!pip install seaborn
Collecting seaborn
  Downloading seaborn-0.13.2-py3-none-any.whl.metadata (5.4 kB)
Requirement already satisfied: numpy!=1.24.0,>=1.20 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
seaborn) (1.26.4)
Requirement already satisfied: pandas>=1.2 in c:\users\jaime\appdata\
local\programs\python\python312\lib\site-packages (from seaborn)
(2.2.1)
Requirement already satisfied: matplotlib!=3.6.1,>=3.4 in c:\users\
jaime\appdata\local\programs\python\python312\lib\site-packages (from
seaborn) (3.8.4)
Requirement already satisfied: contourpy>=1.0.1 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
matplotlib!=3.6.1,>=3.4->seaborn) (1.2.1)
Reguirement already satisfied: cycler>=0.10 in c:\users\jaime\appdata\
local\programs\python\python312\lib\site-packages (from matplotlib!
=3.6.1, >=3.4 -> seaborn) (0.12.1)
Requirement already satisfied: fonttools>=4.22.0 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
matplotlib!=3.6.1,>=3.4->seaborn) (4.51.0)
Requirement already satisfied: kiwisolver>=1.3.1 in c:\users\iaime\
appdata\local\programs\python\python312\lib\site-packages (from
matplotlib!=3.6.1,>=3.4->seaborn) (1.4.5)
Requirement already satisfied: packaging>=20.0 in c:\users\jaime\
appdata\roaming\python\python312\site-packages (from matplotlib!
=3.6.1, >=3.4 -> seaborn) (24.0)
Requirement already satisfied: pillow>=8 in c:\users\jaime\appdata\
local\programs\python\python312\lib\site-packages (from matplotlib!
=3.6.1,>=3.4->seaborn) (10.3.0)
Requirement already satisfied: pyparsing>=2.3.1 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
matplotlib!=3.6.1,>=3.4->seaborn) (3.1.2)
Requirement already satisfied: python-dateutil>=2.7 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
matplotlib!=3.6.1,>=3.4->seaborn) (2.9.0.post0)
Requirement already satisfied: pytz>=2020.1 in c:\users\jaime\appdata\
local\programs\python\python312\lib\site-packages (from pandas>=1.2-
>seaborn) (2024.1)
Requirement already satisfied: tzdata>=2022.7 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
pandas>=1.2->seaborn) (2024.1)
Requirement already satisfied: six>=1.5 in c:\users\jaime\appdata\
local\programs\python\python312\lib\site-packages (from python-
dateutil>=2.7->matplotlib!=3.6.1,>=3.4->seaborn) (1.16.0)
Downloading seaborn-0.13.2-py3-none-any.whl (294 kB)
```

Importamos las librerias necesarias

```
# Importar librerias
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import os
#import missingno as msno
import math
import seaborn as sns
#import statsmodels.api as sm
```

Localizamos donde estan los archivos por medio de la libreria os para mayor robustez del proceso

```
current_directory = os.getcwd()
print(current_directory)

parent_directory=os.path.split(current_directory)[0]
parent_directory

c:\Users\jaime\OneDrive\Documentos\trabajo\dataknow\prueba_tecnica\punto6

'c:\\Users\\jaime\\OneDrive\\Documentos\\trabajo\\dataknow\\
prueba_tecnica'
```

Asignamos la ruta de los archivos y los cargamos.

```
train_file =
os.path.join(parent_directory,'Prueba_Tecnica','Datos3','train.csv')
test_file =
os.path.join(parent_directory,'Prueba_Tecnica','Datos3','test.csv')
```

## # Cargar los datos train data = pd.read csv(train file) test\_data = pd.read\_csv(test\_file) pd.set option('display.max columns', None) train data FRAUDE VAL0R HORA AUX Dist max NAL id Canal1 \ 900000001 0.00 13 659.13 ATM INT 900000002 0.00 17 594.77 ATM INT 2 900000003 0.00 13 1 659.13 ATM INT 900000004 0.00 13 659.13 ATM INT 900000005 0.00 0 1.00 ATM INT 2960 622529101 993430.04 19 180.65 P<sub>0</sub>S 2961 2043206272 9957.05 10 318.50 P<sub>0</sub>S 2962 2943206272 9957.05 10 318.50 P<sub>0</sub>S 2963 3136302872 996191.64 15 234.42 P<sub>0</sub>S 16 2964 1953178702 999276.60 1.00 ATM INT FECHA COD PAIS CANAL DIASEM **DIAMES** FECHA VIN OFICINA VIN 20150501 US ATM INT 5 20120306.0 392.0 US 20150515 ATM INT 15 20050415.0 716.0 US 20120306.0 20150501 ATM INT 1 392.0 3 20150501 US ATM\_INT 20120306.0 392.0 20150510 CR ATM INT 10 20141009.0 788.0 . . . 20150519 US P<sub>0</sub>S 19740401.0 2960 19 442.0 2961 20150524 US P<sub>0</sub>S 19970616.0 611.0 US P<sub>0</sub>S 2962 20150524 24 19970616.0

611.0										
2963	20150513		US MC		1CI	I 3		20000609.0		
534.0 2964	20150520		CR	ATM_	INT	3	20 20050		0630.0	
661.0										
0 1 2 3 4	SEXO M M M M M	Personal Personal Personal	Plus Plus	EDAL 29.6 29.6 29.6 29.6	126 564 126 126	IGRESOS 00000.0 13700.0 00000.0 00000.0	120 50 120	GRESOS 0000.0 0000.0 0000.0 0000.0	NROPAISES	
2960 2961 2962 2963 2964	F F F F	Preferer Preferer Preferer Personal	ncial ncial PYME	35.6 34.6	10391 2362 2362 5666		500 500 3760	5378.0 0000.0 0000.0 0750.0 6000.0		1 3 3 L
0 1 2 3 4  2960 2961	Dist_	_Sum_INTEF NaM NaM NaM NaM  8944.83	             	st_Mea	an_INTER NaN NaN NaN NaN  2236.21			NTER N NaN NaN NaN NaN NaN  6.67	IROCIUDADES	5 5 5 1
2962 2963 2964		27648.32 NaN NaN	<u>2</u> N		3949.76 NaN	5 I		2.41 NaN NaN	11 3	L 3
0 1 2 3 4	Dist_	Mean_NAL 474.94 289.99 474.94 474.94 NaN	45! 45! 45! 45!	t_HOY 52.41 52.41 52.41 52.41 32.35		Sum_NAL 5224.36 2029.90 5224.36 5224.36 1.00				
2960 2961 2962 2963 2964		96.86 82.67 82.67 219.46 NaN	45! 45! 45!	52.41 52.41 52.41 52.41 52.41 82.35	2	484.30 2810.75 2810.75 316.79				
[2965	rows	x 26 colu	umns]							

Observamos el numero de filas no nulas mediante la función info().

```
# Ver información de los datos
print(train data.info())
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2965 entries, 0 to 2964
Data columns (total 26 columns):
#
     Column
                       Non-Null Count
                                        Dtype
- - -
     _ _ _ _ _ _
 0
     id
                       2965 non-null
                                        int64
 1
     FRAUDE
                       2965 non-null
                                        int64
 2
     VALOR
                       2965 non-null
                                        float64
 3
     HORA AUX
                       2965 non-null
                                        int64
 4
                      2965 non-null
     Dist max NAL
                                        float64
 5
                       2965 non-null
     Canal1
                                        object
 6
     FECHA
                       2965 non-null
                                        int64
 7
     COD PAIS
                       2965 non-null
                                        object
 8
     CANAL
                       2965 non-null
                                        object
 9
     DIASEM
                      2965 non-null
                                        int64
 10
     DIAMES
                       2965 non-null
                                        int64
 11
    FECHA VIN
                       2941 non-null
                                        float64
 12
                       2941 non-null
                                        float64
     OFICINA VIN
 13
                       2910 non-null
                                        object
     SEX0
 14
    SEGMENTO
                       2941 non-null
                                        object
 15
     EDAD
                       2941 non-null
                                        float64
 16
    INGRESOS
                       2941 non-null
                                        float64
 17
     EGRESOS
                       2941 non-null
                                        float64
 18
     NROPAISES
                       2965 non-null
                                        int64
 19
     Dist Sum INTER
                      1418 non-null
                                        float64
 20
     Dist Mean INTER 1418 non-null
                                        float64
21
     Dist Max INTER
                      1418 non-null
                                        float64
 22
     NROCIUDADES
                       2965 non-null
                                        int64
23
     Dist Mean NAL
                      2508 non-null
                                        float64
     Dist HOY
 24
                       2965 non-null
                                        float64
     Dist sum NAL
25
                      2965 non-null
                                        float64
dtypes: f\overline{loat64}(13), int64(8), object(5)
memory usage: 602.4+ KB
None
```

Establecemos la cantidad de nulos por cada columna y que porcentaje representan

```
#Conteo de la cantidad de nulos por cada columna
regs=train_data.shape[0]
df_transform=train_data.copy()
for col in train_data.columns:
    vals=train_data[col].value_counts()
    values=vals.shape[0]
    nas=train_data[train_data[col].isna()].shape[0]
    porcentaje_na=nas*100/regs
    if porcentaje_na>=10:
```

```
text=f'elimienando columna: {col}'
        df transform.drop(columns={col},inplace=True)
    else:
        text=f'Quitando nulos de {col}'
        df transform.dropna(subset=col,inplace=True)
    print(f'-variable {col} tiene {values} valores único, {nas}
valores nulos ({nas*100/regs:.2f})%.')
-variable id tiene 2888 valores único, 0 valores nulos (0.00)%.
-variable FRAUDE tiene 2 valores único, 0 valores nulos (0.00)%.
-variable VALOR tiene 2259 valores único, 0 valores nulos (0.00)%.
-variable HORA AUX tiene 24 valores único, 0 valores nulos (0.00)%.
-variable Dist max NAL tiene 264 valores único, 0 valores nulos
(0.00)%.
-variable Canall tiene 2 valores único, 0 valores nulos (0.00)%.
-variable FECHA tiene 31 valores único, 0 valores nulos (0.00)%.
-variable COD PAIS tiene 29 valores único, 0 valores nulos (0.00)%.
-variable CANAL tiene 3 valores único, 0 valores nulos (0.00)%.
-variable DIASEM tiene 7 valores único, 0 valores nulos (0.00)%.
-variable DIAMES tiene 31 valores único, 0 valores nulos (0.00)%.
-variable FECHA VIN tiene 1025 valores único, 0 valores nulos (0.00)%.
-variable OFICINA VIN tiene 373 valores único, 0 valores nulos
(0.00)%.
-variable SEXO tiene 2 valores único, 0 valores nulos (0.00)%.
-variable SEGMENTO tiene 6 valores único, 0 valores nulos (0.00)%.
-variable EDAD tiene 62 valores único, 0 valores nulos (0.00)%.
-variable INGRESOS tiene 500 valores único, 0 valores nulos (0.00)%.
-variable EGRESOS tiene 193 valores único, 0 valores nulos (0.00)%.
-variable NROPAISES tiene 8 valores único, 0 valores nulos (0.00)%.
-variable Dist Sum INTER tiene 209 valores único, 0 valores nulos
(0.00)%.
-variable Dist_Mean_INTER tiene 182 valores único, 0 valores nulos
(0.00)%.
-variable Dist Max INTER tiene 62 valores único, 0 valores nulos
(0.00)%.
-variable NROCIUDADES tiene 18 valores único, 0 valores nulos (0.00)%.
-variable Dist Mean NAL tiene 772 valores único, 0 valores nulos
(0.00)%.
-variable Dist HOY tiene 48 valores único, 0 valores nulos (0.00)%.
-variable Dist sum NAL tiene 841 valores único, 0 valores nulos
(0.00)%.
```

Observamos la cantidad de subniveles que hay por cada columna, para visualizar si hay algunas columna para descartar en el analisis

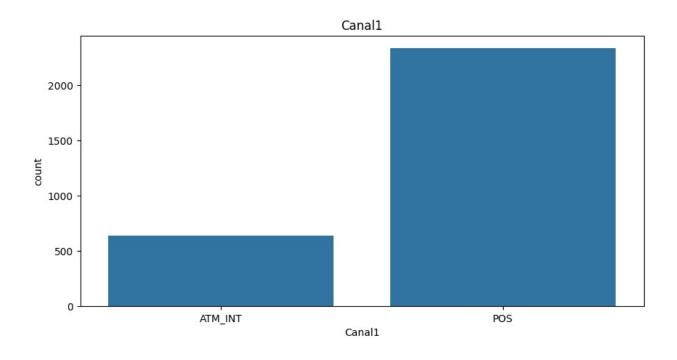
```
cols_cat = train_data.select_dtypes(include=['object'])
```

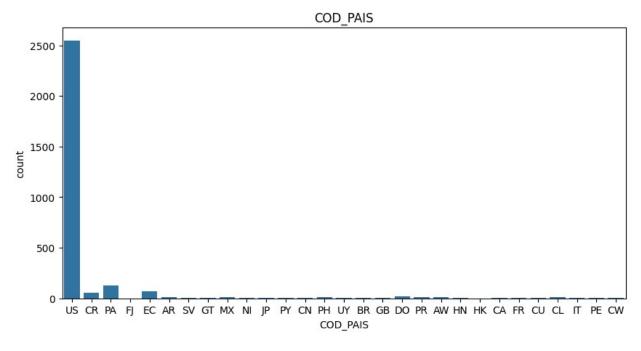
```
for col in cols_cat:
    print(f'Columna {col}: {train_data[col].nunique()} subniveles')

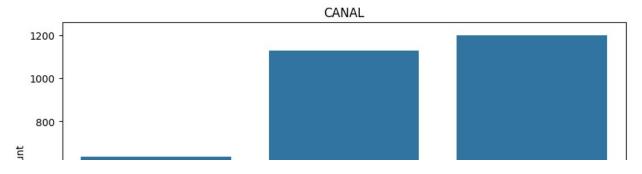
Columna Canall: 2 subniveles
Columna COD_PAIS: 29 subniveles
Columna CANAL: 3 subniveles
Columna SEXO: 2 subniveles
Columna SEGMENTO: 6 subniveles
```

## Grafico de barras de frencuencia

```
fig, ax = plt.subplots(nrows=\frac{5}{1}, ncols=\frac{1}{1}, figsize=\frac{10}{30})
fig.subplots adjust(hspace=0.3)
for i, col in enumerate(cols cat):
  sns.countplot(x=col, data=train data, ax=ax[i])
  ax[i].set title(col)
  ax[i].set xticklabels(ax[i].get xticklabels(),rotation=0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\3464803981.py:7:
UserWarning: set ticklabels() should only be used with a fixed number
of ticks, i.e. after set ticks() or using a FixedLocator.
  ax[i].set xticklabels(ax[i].get xticklabels(),rotation=0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\3464803981.py:7:
UserWarning: set ticklabels() should only be used with a fixed number
of ticks, i.e. after set ticks() or using a FixedLocator.
  ax[i].set xticklabels(ax[i].get xticklabels(),rotation=0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\3464803981.py:7:
UserWarning: set ticklabels() should only be used with a fixed number
of ticks, i.e. after set ticks() or using a FixedLocator.
  ax[i].set xticklabels(ax[i].get xticklabels(),rotation=0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\3464803981.py:7:
UserWarning: set ticklabels() should only be used with a fixed number
of ticks, i.e. after set ticks() or using a FixedLocator.
  ax[i].set xticklabels(ax[i].get xticklabels(),rotation=0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\3464803981.py:7:
UserWarning: set ticklabels() should only be used with a fixed number
of ticks, i.e. after set ticks() or using a FixedLocator.
  ax[i].set xticklabels(ax[i].get xticklabels(),rotation=0)
```







train_data.describe	()		
id Dist max NAL \	FRAUDE	VALOR	HORA_AUX
count 2.965000e+03 2965.000000	2965.000000	2.965000e+03	2965.000000
mean 6.890938e+09 314.656739	0.246543	5.035695e+05	14.960877
std 9.739700e+09 295.142673	0.431071	9.859497e+05	6.348607
min 2.364560e+06 1.000000	0.000000	0.000000e+00	0.000000
25% 2.552997e+09 24.830000	0.000000	9.016001e+04	12.000000
50% 6.142884e+09 243.620000	0.000000	2.435912e+05	16.000000
75% 9.000000e+09 594.770000	0.000000	5.058190e+05	20.000000
max 9.330050e+10 1310.460000	1.000000	2.001406e+07	23.000000
	DIASEM	DTAMES	FECHA VTN
OFICINA_VIN \ count 2.965000e+03			2.941000e+03
2941.000000 mean 2.015051e+07	3.143002	13.492411	2.000920e+07
416.426386 std 9.134641e+00	2.092284	9.134641	9.260427e+04
290.263484 min 2.015050e+07	0.000000	1.000000	1.911111e+07
1.000000 25% 2.015050e+07	1.000000	4.000000	1.995102e+07
168.000000 50% 2.015052e+07	3.000000	15.000000	2.001123e+07
360.000000 75% 2.015052e+07	5.000000	21.000000	2.008081e+07
659.000000 max 2.015053e+07 967.000000	6.000000	31.000000	2.015043e+07
907.000000 EDAD	INGRESOS	EGRES0S	NROPAISES
Dist_Sum_INTER \ count 2941.000000			
1418.000000	2.941000e+03	2.941000e+03	2965.000000
mean 40.010541 17354.692891	1.449104e+07	8.506309e+06	1.765936
std 12.976492 25168.020649	5.637311e+07	6.179161e+07	1.042219

```
0.000000e+00
                                    0.000000e+00
                                                      1.000000
min
          0.000000
904.810000
25%
         31.000000
                     2.500000e+06
                                    5.000000e+05
                                                      1.000000
6474,200000
50%
         38,000000
                     5.800000e+06
                                    1.800000e+06
                                                      1.000000
9104.820000
75%
         47.000000
                     1.274000e+07
                                                      2.000000
                                    4.500000e+06
21376.445000
                     1.940070e+09
max
        133.000000
                                    1.600000e+09
                                                      9.000000
758837.940000
       Dist Mean INTER
                         Dist Max INTER
                                                        Dist Mean NAL
                                          NROCIUDADES
           1418.000000
                            1418.000000
                                          2965.000000
                                                          2508.000000
count
                                                           196.589282
           4144.323540
                            4985,442313
                                              3.943676
mean
                            2655.081718
std
           1794.829357
                                             2.750021
                                                           192.026206
            904.810000
                             904.810000
                                             1.000000
                                                              4.480000
min
25%
                            4552,410000
                                             2,000000
           3178.210000
                                                            60.800000
50%
           4552.410000
                            4552.410000
                                             3.000000
                                                           127.700000
75%
           4552.410000
                            4552.410000
                                             5.000000
                                                           269.082500
          16328.810000
                           17780.330000
                                            20.000000
                                                          1217.570000
max
           Dist HOY
                      Dist sum NAL
        2965.000000
                       2965.000000
count
        4379.826287
                       1765,212887
mean
std
        1779.739070
                       2398,666844
min
           0.000000
                          1.000000
25%
        4552.410000
                        139.870000
                        836.080000
50%
        4552.410000
75%
        4552.410000
                       2533.440000
                      18832.060000
       21991.200000
max
```

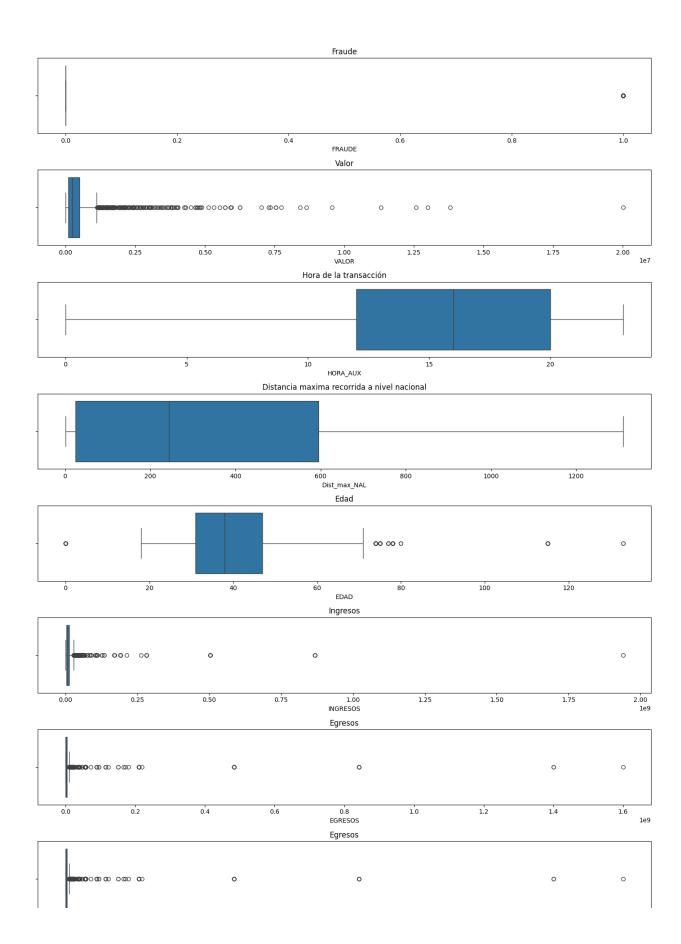
Busqueda de outliers por medio de diagrama de caja

```
train data.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2965 entries, 0 to 2964
Data columns (total 26 columns):
#
     Column
                       Non-Null Count
                                        Dtype
 0
                       2965 non-null
                                        int64
     id
 1
     FRAUDE
                       2965 non-null
                                        int64
 2
     VALOR
                       2965 non-null
                                        float64
 3
     HORA AUX
                       2965 non-null
                                        int64
 4
     Dist max NAL
                       2965 non-null
                                        float64
 5
     Canal1
                       2965 non-null
                                        object
                                        int64
 6
     FECHA
                       2965 non-null
 7
     COD PAIS
                       2965 non-null
                                        object
 8
     CANAL
                       2965 non-null
                                        object
```

```
9
     DIASEM
                      2965 non-null
                                      int64
 10
    DIAMES
                      2965 non-null
                                      int64
 11 FECHA VIN
                      2941 non-null
                                      float64
 12
    OFICINA VIN
                      2941 non-null
                                      float64
13 SEX0
                      2910 non-null
                                      object
14 SEGMENTO
                      2941 non-null
                                      object
15 EDAD
                      2941 non-null
                                      float64
                      2941 non-null
                                      float64
16 INGRESOS
 17 EGRESOS
                      2941 non-null
                                      float64
18 NROPAISES
                      2965 non-null
                                      int64
 19 Dist Sum INTER
                      1418 non-null
                                      float64
20 Dist Mean INTER 1418 non-null
                                      float64
 21
    Dist Max INTER
                      1418 non-null
                                      float64
 22
    NROCIUDADES
                      2965 non-null
                                      int64
23
    Dist Mean NAL
                      2508 non-null
                                      float64
24
    Dist HOY
                      2965 non-null
                                      float64
25
     Dist sum NAL
                     2965 non-null
                                      float64
dtypes: f\overline{l}oat\overline{6}4(13), int64(8), object(5)
memory usage: 602.4+ KB
train data.columns
Index(['id', 'FRAUDE', 'VALOR', 'HORA AUX', 'Dist max NAL', 'Canal1',
'FECHA'
       COD PAIS', 'CANAL', 'DIASEM', 'DIAMES', 'FECHA_VIN',
'OFICINA VIN',
       'SEXO', 'SEGMENTO', 'EDAD', 'INGRESOS', 'EGRESOS', 'NROPAISES',
       'Dist Sum INTER', 'Dist Mean INTER', 'Dist Max INTER',
'NROCIUDADES',
       'Dist Mean NAL', 'Dist HOY', 'Dist sum NAL'],
      dtype='object')
# Crear el boxplot
plt.figure(figsize=(14, 40)) # Ajusta el tamaño de la gráfica
# Boxplot para la Columna1
plt.subplot(16, 1, 1)
sns.boxplot(x='FRAUDE', data=train_data)
plt.title("Fraude")
# Boxplot para la Columna2
plt.subplot(16, 1, 2)
sns.boxplot(x='VALOR', data=train data)
plt.title("Valor")
# Boxplot para la Columna3
plt.subplot(16, 1, 3)
sns.boxplot(x='HORA AUX', data=train data)
plt.title("Hora de la transacción")
```

```
# Boxplot para la Columna4
plt.subplot(16, 1, 4)
sns.boxplot(x='Dist max NAL', data=train data)
plt.title("Distancia maxima recorrida a nivel nacional")
# Boxplot para la Columna5
plt.subplot(16, 1, 5)
sns.boxplot(x='EDAD', data=train data)
plt.title("Edad")
# Boxplot para la Columna6
plt.subplot(16, 1, 6)
sns.boxplot(x='INGRESOS', data=train_data)
plt.title("Ingresos")
# Boxplot para la Columna7
plt.subplot(16, 1, 7)
sns.boxplot(x='EGRESOS', data=train data)
plt.title("Egresos")
# Boxplot para la Columna8
plt.subplot(16, 1, 8)
sns.boxplot(x='EGRESOS', data=train data)
plt.title("Egresos")
# Boxplot para la Columna9
plt.subplot(16, 1, 9)
sns.boxplot(x='NROPAISES', data=train_data)
plt.title("Numero de paises visitados")
# Boxplot para la Columna10
plt.subplot(16, 1, 10)
sns.boxplot(x='Dist Sum INTER', data=train data)
plt.title("Sumatoria de distancia recorrida a nivel internacional (en
millas)")
# Boxplot para la Columna11
plt.subplot(16, 1, 11)
sns.boxplot(x='Dist Mean INTER', data=train data)
plt.title("Promedio de distancia recorrida a nivel internacional (en
millas)")
# Boxplot para la Columna12
plt.subplot(16, 1, 12)
sns.boxplot(x='Dist Max INTER', data=train data)
plt.title("Distancia maxima recorrida a nivel internacional (en
millas)")
# Boxplot para la Columna13
plt.subplot(16, 1, 13)
```

```
sns.boxplot(x='NROCIUDADES', data=train data)
plt.title("Numero de ciudades nacionales visitadas")
# Boxplot para la Columna14
plt.subplot(16, 1, 14)
sns.boxplot(x='Dist_Mean_NAL', data=train_data)
plt.title("Distancia máxima recorrida a nivel nacional (en millas)")
# Boxplot para la Columna15
plt.subplot(16, 1, 15)
sns.boxplot(x='Dist HOY', data=train data)
plt.title("Diferencia entre la ultima transacción presente realizada y
la transacción que esta realizando el dia de hoy")
# Boxplot para la Columna16
plt.subplot(16, 1, 16)
sns.boxplot(x='Dist_sum_NAL', data=train_data)
plt.title("Sumatoria de distacia recorrida a nivel nacional (en
millas)")
# Ajustar el diseño y mostrar la gráfica
plt.tight_layout()
plt.show()
```



Eliminacion e imputacion de valores segun el porcentaje de nulos y la relevancia de la variable para el analisis

```
train data = train data.dropna(subset=['FECHA VIN', 'OFICINA VIN',
'SEGMENTO', 'INGRESOS', 'EGRESOS'])
train data['EDAD'] =
train data['EDAD'].fillna(train data['EDAD'].median())
train data['SEX0'] =
train data['SEXO'].fillna(train data['SEXO'].mode()[0])
train data['Dist Sum INTER'] = train data['Dist Sum INTER'].fillna(0)
train data['Dist Mean INTER'] =
train_data['Dist_Mean_INTER'].fillna(0)
train data['Dist Max INTER'] = train data['Dist Max INTER'].fillna(0)
train data['Dist Mean NAL'] = train data['Dist Mean NAL'].fillna(0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\1449264375.py:2:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row indexer,col indexer] = value instead
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user guide/indexing.html#
returning-a-view-versus-a-copy
  train data['EDAD'] =
train data['EDAD'].fillna(train data['EDAD'].median())
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\1449264375.py:3:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row indexer,col indexer] = value instead
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#
returning-a-view-versus-a-copy
  train data['SEXO'] =
train data['SEXO'].fillna(train data['SEXO'].mode()[0])
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\1449264375.py:4:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row indexer,col indexer] = value instead
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#
returning-a-view-versus-a-copy
  train data['Dist Sum INTER'] =
train data['Dist Sum INTER'].fillna(0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\1449264375.py:5:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row indexer,col indexer] = value instead
```

```
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#
returning-a-view-versus-a-copy
  train data['Dist Mean INTER'] =
train data['Dist Mean INTER'].fillna(0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\1449264375.py:6:
SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row indexer,col indexer] = value instead
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user guide/indexing.html#
returning-a-view-versus-a-copy
  train data['Dist Max INTER'] =
train data['Dist Max INTER'].fillna(0)
C:\Users\jaime\AppData\Local\Temp\ipykernel 3692\1449264375.py:7:
SettingWithCopvWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row indexer,col indexer] = value instead
See the caveats in the documentation:
https://pandas.pydata.org/pandas-docs/stable/user guide/indexing.html#
returning-a-view-versus-a-copy
 train data['Dist Mean NAL'] = train data['Dist Mean NAL'].fillna(0)
#Conteo de la cantidad de nulos por cada columna
regs=train data.shape[0]
df transform=train data.copy()
for col in train data.columns:
    vals=train data[col].value counts()
    values=vals.shape[0]
    nas=train data[train data[col].isna()].shape[0]
    porcentaje na=nas*100/regs
    if porcentaje na>=10:
        text=f'elimienando columna: {col}'
        df transform.drop(columns={col},inplace=True)
    else:
        text=f'Ouitando nulos de {col}'
        df transform.dropna(subset=col,inplace=True)
    print(f'-variable {col} tiene {values} valores único, {nas}
valores nulos ({nas*100/regs:.2f})%.')
-variable id tiene 2888 valores único, 0 valores nulos (0.00)%.
-variable FRAUDE tiene 2 valores único, 0 valores nulos (0.00)%.
-variable VALOR tiene 2259 valores único, 0 valores nulos (0.00)%.
-variable HORA AUX tiene 24 valores único, 0 valores nulos (0.00)%.
-variable Dist max_NAL tiene 264 valores único, 0 valores nulos
-variable Canall tiene 2 valores único, 0 valores nulos (0.00)%.
```

```
-variable FECHA tiene 31 valores único, 0 valores nulos (0.00)%.
-variable COD PAIS tiene 29 valores único, 0 valores nulos (0.00)%.
-variable CANAL tiene 3 valores único, 0 valores nulos (0.00)%.
-variable DIASEM tiene 7 valores único, 0 valores nulos (0.00)%.
-variable DIAMES tiene 31 valores único, 0 valores nulos (0.00)%.
-variable FECHA VIN tiene 1025 valores único, 0 valores nulos (0.00)%.
-variable OFICINA VIN tiene 373 valores único, O valores nulos
(0.00)%.
-variable SEXO tiene 2 valores único, 0 valores nulos (0.00)%.
-variable SEGMENTO tiene 6 valores único, 0 valores nulos (0.00)%.
-variable EDAD tiene 62 valores único, 0 valores nulos (0.00)%.
-variable INGRESOS tiene 500 valores único, 0 valores nulos (0.00)%.
-variable EGRESOS tiene 193 valores único, 0 valores nulos (0.00)%.
-variable NROPAISES tiene 8 valores único, 0 valores nulos (0.00)%.
-variable Dist Sum INTER tiene 209 valores único, O valores nulos
(0.00)%.
-variable Dist Mean INTER tiene 182 valores único, 0 valores nulos
(0.00)%.
-variable Dist Max INTER tiene 62 valores único, 0 valores nulos
(0.00)%.
-variable NROCIUDADES tiene 18 valores único, 0 valores nulos (0.00)%.
-variable Dist Mean NAL tiene 772 valores único, 0 valores nulos
(0.00)%.
-variable Dist HOY tiene 48 valores único, 0 valores nulos (0.00)%.
-variable Dist sum NAL tiene 841 valores único, 0 valores nulos
(0.00)%.
train data.info()
<class 'pandas.core.frame.DataFrame'>
Index: 2941 entries, 0 to 2964
Data columns (total 26 columns):
#
     Column
                      Non-Null Count
                                      Dtype
- - -
     -----
 0
     id
                      2941 non-null
                                      int64
                      2941 non-null
 1
     FRAUDE
                                      int64
 2
     VALOR
                      2941 non-null
                                      float64
 3
                      2941 non-null
     HORA AUX
                                      int64
    Dist max NAL
 4
                      2941 non-null
                                       float64
 5
     Canal1
                      2941 non-null
                                      object
 6
     FECHA
                      2941 non-null
                                      int64
 7
     COD PAIS
                      2941 non-null
                                      object
 8
     CANAL
                      2941 non-null
                                      object
 9
     DIASEM
                      2941 non-null
                                      int64
 10
    DIAMES
                      2941 non-null
                                      int64
 11
    FECHA VIN
                      2941 non-null
                                      float64
 12
                      2941 non-null
                                      float64
    OFICINA VIN
 13
    SEX0
                      2941 non-null
                                      object
 14
    SEGMENTO
                      2941 non-null
                                      object
 15 EDAD
                      2941 non-null
                                      float64
```

```
16
    INGRESOS
                      2941 non-null
                                      float64
 17
    EGRESOS
                      2941 non-null
                                      float64
 18 NROPAISES
                      2941 non-null
                                      int64
    Dist_Sum INTER
 19
                     2941 non-null
                                      float64
 20 Dist Mean INTER 2941 non-null
                                      float64
    Dist Max INTER
 21
                     2941 non-null
                                      float64
22 NROCIUDADES
                     2941 non-null
                                      int64
23 Dist Mean_NAL
                    2941 non-null
                                      float64
    Dist HOY
 24
                     2941 non-null
                                      float64
25
    Dist sum NAL
                    2941 non-null
                                      float64
dtypes: f\overline{loat64}(13), int64(8), object(5)
memory usage: 620.4+ KB
```

## Entrenamiento del modelo

```
!pip install -U scikit-learn
Collecting scikit-learn
 Downloading scikit learn-1.5.2-cp312-cp312-win amd64.whl.metadata
(13 \text{ kB})
Requirement already satisfied: numpy>=1.19.5 in c:\users\jaime\
appdata\local\programs\python\python312\lib\site-packages (from
scikit-learn) (1.26.4)
Collecting scipy>=1.6.0 (from scikit-learn)
 Downloading scipy-1.14.1-cp312-cp312-win_amd64.whl.metadata (60 kB)
   ----- 0.0/60.8 kB ? eta
   ----- 10.2/60.8 kB ? eta
-:--:--
   ----- 60.8/60.8 kB 1.6 MB/s
eta 0:00:00
Collecting joblib>=1.2.0 (from scikit-learn)
 Downloading joblib-1.4.2-py3-none-any.whl.metadata (5.4 kB)
Collecting threadpoolctl>=3.1.0 (from scikit-learn)
 Downloading threadpoolctl-3.5.0-py3-none-any.whl.metadata (13 kB)
Downloading scikit learn-1.5.2-cp312-cp312-win amd64.whl (11.0 MB)
  ----- 0.0/11.0 MB ? eta -:--:--
  ---- 1.2/11.0 MB 37.1 MB/s eta
0:00:01
  ----- 3.7/11.0 MB 46.5 MB/s eta
0:00:01
  ----- 6.1/11.0 MB 55.4 MB/s eta
0:00:01
  ----- 8.5/11.0 MB 54.1 MB/s eta
0:00:01
  ----- 11.0/11.0 MB 73.1 MB/s eta
0:00:01
  ----- 11.0/11.0 MB 59.5 MB/s eta
0:00:00
```

Downloading joblib-1.4.2-py3-none-any.whl (3	0.0/301.8 kB ? eta -::
0:00:00 Downloading scipy-1.14.1-cp312-cp312-win_amo	d64.whl (44.5 MB)
	0.0/44.5 MB ? eta -::-
0:00:01	
0:00:01	5.7/44.5 MB 72.7 MB/s eta
0:00:01	8.4/44.5 MB 67.1 MB/s eta
	11.0/44.5 MB 72.6 MB/s eta
0:00:01	12.9/44.5 MB 65.6 MB/s eta
0:00:01	· ·
0:00:01	14.6/44.5 MB 59.5 MB/s eta
0:00:01	17.4/44.5 MB 59.5 MB/s eta
	19.9/44.5 MB 54.4 MB/s eta
0:00:01	22.3/44.5 MB 54.7 MB/s eta
0:00:01	24.3/44.5 MB 65.6 MB/s eta
0:00:01	
0:00:01	25.9/44.5 MB 65.2 MB/s eta
0:00:01	28.3/44.5 MB 54.7 MB/s eta
	30.5/44.5 MB 50.4 MB/s eta
0:00:01	33.6/44.5 MB 50.4 MB/s eta
0:00:01	36 5/44 5 MR 65 6 MR/s eta
0:00:01	
0:00:01	
0:00:01	39.0/44.5 MB 54.7 MB/s eta
	42.3/44.5 MB 54.7 MB/s eta
0:00:01	44.5/44.5 MB 54.7 MB/s eta
0:00:01	44.5/44.5 MB 54.7 MB/s eta
0:00:01	
0:00:00	44.5/44.5 MB 36.4 MB/s eta
Downloading threadpoolctl-3.5.0-py3-none-any	/.whl (18 kB)

```
Installing collected packages: threadpoolctl, scipy, joblib, scikit-
learn
Successfully installed joblib-1.4.2 scikit-learn-1.5.2 scipy-1.14.1
threadpoolctl-3.5.0

[notice] A new release of pip is available: 24.0 -> 24.2
[notice] To update, run: python.exe -m pip install --upgrade pip
```

División en datos de entrenamiento, validacion y evaluación

```
from sklearn.model_selection import train_test_split

# Dividir el dataset de entrenamiento
X = train_data.drop('FRAUDE', axis=1)
y = train_data['FRAUDE']

# Dividir en conjunto de entrenamiento y validación
X_train, X_val, y_train, y_val = train_test_split(X, y, test_size=0.2, random_state=42)
```

Contrucción del pipeline para el entranamiento y evalaución del modelo usando random forest y grid seach para la busqueda de los mejores hiperparametros

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
from sklearn.metrics import accuracy score, f1 score, make scorer
# Columnas categóricas
columnas categoricas = ['Canal1', 'COD PAIS', 'CANAL', 'SEXO',
'SEGMENTO'1
# Preprocesamiento
preprocesamiento = ColumnTransformer(
    transformers=[
        # No preprocesamos las columnas numéricas
        ('categorico', Pipeline([
            ('onehotencoder', OneHotEncoder(handle_unknown='ignore',
sparse output=False)) # Codificación one-hot sin salida esparcida
        ]), columnas categoricas)
    ],
    remainder='passthrough' # Deja pasar las columnas no
especificadas (en este caso, las numéricas)
# Pipeline con RandomForest
```

```
pipeline rf = Pipeline([
    ('preprocesador', preprocesamiento),
    ('classifier', RandomForestClassifier(class_weight='balanced',
random state=42))
1)
# Configuración de la malla de búsqueda (hiperparámetros para ajustar)
malla rf = {
    'classifier__n_estimators': [50, 100, 200], # Número de árboles
    'classifier__max_depth': [None, 10, 20], # Profundidad máxima del
árbol
    'classifier min samples split': [2, 5, 10], # Mínimo número de
muestras para dividir un nodo
    'classifier min samples leaf': [1, 2, 4], # Mínimo número de
muestras en una hoja
    'classifier bootstrap': [True, False] # Si utilizar o no
bootstrap
}
# Crea el GridSearchCV
grid rf = GridSearchCV(pipeline rf, param grid=malla rf,
                       cv=5, # Validación cruzada de 5
                       scoring={'accuracy':
make scorer(accuracy_score),
                                'f1': make scorer(f1 score)}, #
Métricas de evaluación
                       refit='f1', # Métrica principal para refit
                       return train score=True)
# Ajustar el modelo con GridSearch
grid_rf.fit(X_train, y train)
# Mejores parámetros encontrados por GridSearch
print(f'Mejores Parametros: {grid rf.best params }')
Mejores Parametros: {'classifier bootstrap': False,
'classifier max depth': None, 'classifier min samples leaf': 1,
'classifier min samples_split': 2, 'classifier__n_estimators': 200}
```

## Evaluación del modelo

```
from sklearn.metrics import accuracy_score, f1_score

# Predecir y evaluar en el conjunto de validación
y_pred = grid_rf.predict(X_val)

print(f'Accuracy: {accuracy_score(y_val, y_pred)}')
print(f'F1-Score: {f1_score(y_val, y_pred)}')
```

```
Accuracy: 0.969439728353141
F1-Score: 0.9411764705882353
```

Generación del archivo de predicciones "predicciones\_fraude.csv"

```
# Predecir en el archivo de prueba
predicciones_test = grid_rf.predict(test_data)

# Guardar las predicciones
output = pd.DataFrame({'id': test_data['id'], 'FRAUDE':
predicciones_test})
output.to_csv('predicciones_fraude.csv', index=False)
!pip install numpy

Requirement already satisfied: numpy in c:\users\jaime\appdata\local\
programs\python\python312\lib\site-packages (1.26.4)

[notice] A new release of pip is available: 24.0 -> 24.2
[notice] To update, run: python.exe -m pip install --upgrade pip
```

Matriz de confusión y comparación de las predicciones con los datos de validación

```
from sklearn.metrics import confusion_matrix, accuracy_score, f1_score

# Comparar y_pred (predicciones) y y_val (valores reales)
matriz_confusion = confusion_matrix(y_val, y_pred)
accuracy = accuracy_score(y_val, y_pred)
f1 = f1_score(y_val, y_pred)

print("Matriz de confusión:")
print(matriz_confusion)

print(f"Accuracy: {accuracy}")
print(f"F1 Score: {f1}")

Matriz de confusión:
[[427 10]
  [ 8 144]]
Accuracy: 0.969439728353141
F1 Score: 0.9411764705882353
```